

Detección de spam en correo electrónico

Naive Bayes frente a perceptrón multicapa (MLP)

Santiago Puerta · santiago.puerta@upb.edu.co

Iker Acevedo Vargas · iker.acevedo@upb.edu.co

Contenido

1. Descripción del problema
2. Estado del arte
3. Metodología y experimento
4. Resultados
5. Conclusiones

1. Descripción del problema

Contexto

- Se estima que **cada día** se envían **160 mil millones** de correos electrónicos no deseados^[1].
- Las **instituciones financieras** concentran cerca del **27 %** de los mensajes fraudulentos (objetivos frecuentes de atacantes)^[1].
- En **servicios de entrega**, alrededor de **1.100 millones** de mensajes fraudulentos estuvieron relacionados con este tema, con impacto en confianza y reputación^[1].

[1] C. Ellis y R. Brandl, «Spam Statistics 2026: Survey on Junk Email, AI Scams y Phishing», EmailTooltester, oct. 2024.

2. Estado del arte

Panorama

- El spam ha impulsado la evolución de detectores: desde **reglas heurísticas** y **NB / SVM** hasta **embeddings, MLP** y **modelos de lenguaje** como BERT^[2,3].
- **Naive Bayes** sigue siendo referencia en texto por **simplicidad, velocidad** y buen rendimiento en muchos corpus^[2].
- La literatura discute **representación** (palabras vs n-gramas de caracteres), **variantes de NB** y **trade-off** precisión vs coste.

[2] X. Wang, «Spam Filtering in the Modern Era: A Review of Machine Learning, Deep Learning, and System Comparisons», en *Proc. 2nd Int. Conf. Data Analysis and Machine Learning (DAML)*, 2024, pp. 451-458, doi: 10.5220/0013526000004619.

[3] S. Kaddoura et al., «A systematic literature review on spam content detection and classification», *PeerJ Computer Science*, vol. 8, e830, 2022, doi: 10.7717/peerj-cs.830.

Trabajos representativos (I)

Referencia	Conjunto de datos	Idea clave	Mejor modelo
Metsis et al. (2006)	Enron-Spam (6 subconjuntos, ~5 000–6 000 mensajes c/u)	Comparación de variantes de NB; la variante y la binarización importan.	Multinomial con atributos booleanos — mejor balance precisión/eficiencia.
Mohammed et al. (2013)	Email-1431 (544 correos balanceados)	Léxico dinámico + varios clasificadores; léxicos evolucionan .	NB y SVM empatados como los más efectivos.
Fusilier et al. (2015)	1 600 reseñas de hoteles	N-gramas de caracteres ; mejora frente a n-gramas de palabras entre 2.1–2.3 %.	Multinomial NB con n-gramas de caracteres.

Trabajos representativos (II)

Referencia	Conjunto de datos	Idea clave	Mejor modelo
Hammad & El-Halees (2013)	Reseñas de hoteles en árabe	Características de contenido, metadatos y atributos del autor.	Naive Bayes — 99.2 % de precisión.
Wu et al. (2017)	Twitter (+2 M de mensajes)	Word2Vec/Doc2Vec + modelos profundos; NB sensible al desbalance .	MLP — ~95 %, superando a NB (80–85 %).
Aiyar & Shetty (2018)	13 000 comentarios de YouTube	N-gramas de caracteres; NB el más bajo al crecer n .	SVM con 6-gramas de caracteres.

Trabajos representativos (III)

Referencia	Conjunto de datos	Idea clave	Mejor modelo
Mani et al. (2018)	Reseñas en inglés	Ensamble NB + RF + SVM compensa limitaciones individuales.	Ensamble (NB + RF + SVM) — 87.68 % de precisión.
Saeed et al. (2019)	2 corpus de reseñas de hoteles en árabe	Stacking + módulo de negaciones; NB destacado dentro del ensamble.	Stacking — >95 % de precisión.
Kontsewaya et al. (2021)	5 728 correos en inglés (Kaggle)	NB y regresión logística muy altos; palabras OOV [†] limitan NB.	Regresión Logística y NB — ~99 % de precisión.

[†] *OOV (Out-Of-Vocabulary)*: términos que no aparecieron en el conjunto de entrenamiento y que el modelo no puede representar directamente, lo que puede afectar negativamente su probabilidad estimada.

Síntesis

- **NB** sigue siendo **baseline fuerte** no solo en spam de correo electrónico, sino también en detección de spam en **reseñas, redes sociales y foros** (YouTube, Twitter, hoteles) — lo que evidencia su versatilidad más allá del correo.
 - Modelos **más expresivos** pueden ganar según **corpus, desbalance y representación**.
 - **Wang (2024)**: revisión moderna — NB eficiente; modelos profundos captan más **contexto**; retos: *concept drift*, spam asistido por LLM.
- Motiva una comparación **controlada** NB vs MLP en **un mismo pipeline** (este proyecto).

Pregunta de investigación

En el estado del arte se han evaluado, entre otros, **Naive Bayes** (variantes), **SVM**, **bosques / ensambles**, **MLP** y representaciones más ricas (**Word2Vec**, **Doc2Vec**, modelos de lenguaje) — con distintos **trade-offs** entre precisión y coste.

¿Un modelo más complejo (MLP) ofrece mejor desempeño que una familia de modelos simples (Naive Bayes)?

- Se contrasta no solo la **calidad de predicción**, sino también el **coste computacional** y la **aplicabilidad** (curvas de aprendizaje, tiempos de entrenamiento e inferencia).

¿Qué es Naive Bayes?

Una **familia** de clasificadores probabilísticos basados en el **Teorema de Bayes** con la suposición de **independencia condicional** entre características:

$$P(C | X) = \frac{P(X | C) P(C)}{P(X)}$$

¿Por qué funciona tan bien para spam?

- El spam suele estar dominado por **patrones léxicos repetitivos** (palabras clave, frases promocionales) que se detectan eficientemente con probabilidades por término.
- **Baja complejidad computacional** — ideal para grandes volúmenes de correos.
- **Buena generalización** con pocos datos de entrenamiento gracias al *prior* bayesiano.
- Robusto ante vocabularios grandes y dispersos (característica típica del texto).

Bernoulli NB — Presencia o ausencia

Representa cada mensaje como un **vector binario**: 1 si la palabra está, 0 si no.

$$P(C \mid X) = \frac{\left[\prod_{i=1}^n P(x_i \mid C)^{x_i} (1 - P(x_i \mid C))^{1-x_i} \right] \cdot P(C)}{P(X)}$$

$$P(X) = \prod_{i=1}^n P(x_i \mid \text{Spam})^{x_i} (1 - P(x_i \mid \text{Spam}))^{1-x_i} \cdot P(\text{Spam}) \\ + \prod_{i=1}^n P(x_i \mid \text{Ham})^{x_i} (1 - P(x_i \mid \text{Ham}))^{1-x_i} \cdot P(\text{Ham})$$

Caso de uso típico: mensajes cortos o SMS donde la presencia de ciertas palabras ya es señal suficiente.

† El factor $(1 - P(x_i \mid C))$ representa la probabilidad de que la palabra esté *ausente* dado que el mensaje pertenece a la clase C . Cuando $x_i = 0$ este factor se activa, penalizando o favoreciendo la clase según cuán frecuente sea ese término en ella.

Bernoulli NB — Limitaciones

 Limitación	Explicación
Ignora la frecuencia	"Premio Premio Premio" se trata igual que "Premio" — el modelo no distingue cuántas veces aparece un término, perdiendo una señal discriminativa clave en spam.
Evalúa todo el vocabulario	Un mensaje de 2 palabras con vocabulario de 5 000 requiere un vector de 5 000 posiciones (4 998 ceros). Además, las probabilidades pequeñas de los términos ausentes van diluyendo el producto del likelihood — análogo al desvanecimiento del gradiente .
Sensible al tamaño del vocabulario	A mayor vocabulario, más términos ausentes participan en el cálculo del evidence, amplificando el efecto de dilución y pudiendo sesgar la clasificación hacia la clase con mayor prior.

Bernoulli NB — Caso práctico

Escenario: 80 HAM / 20 SPAM · Vocabulario: {premio, ganaste, gratis, dinero, oferta} ·

Mensaje: "*Premio Ganaste*" → vector (1, 1, 0, 0, 0)

Posterior:

$$P(\text{Spam} \mid \text{mensaje}) = \frac{[P(\text{premio} \mid \text{Sp}) \cdot P(\text{ganaste} \mid \text{Sp}) \cdot (1 - P(\text{gratis} \mid \text{Sp})) \cdot (1 - P(\text{dinero} \mid \text{Sp})) \cdot (1 - P(\text{oferta} \mid \text{Sp}))] \cdot P(\text{Sp})}{P(X)}$$

Evidence:

$$P(X) = [P(\text{premio} \mid \text{Sp}) \cdot P(\text{ganaste} \mid \text{Sp}) \cdot (1 - P(\text{gratis} \mid \text{Sp})) \cdot (1 - P(\text{dinero} \mid \text{Sp})) \cdot (1 - P(\text{oferta} \mid \text{Sp})) \cdot P(\text{Sp})] \\ + [P(\text{premio} \mid \text{Ham}) \cdot P(\text{ganaste} \mid \text{Ham}) \cdot (1 - P(\text{gratis} \mid \text{Ham})) \cdot (1 - P(\text{dinero} \mid \text{Ham})) \cdot (1 - P(\text{oferta} \mid \text{Ham})) \cdot P(\text{Ham})]$$

† Los 3 términos ausentes (gratis, dinero, oferta) participan activamente mediante los factores $(1 - P(x_i \mid C))$ tanto en el **likelihood** del numerador como en el cálculo del **evidence**, diluyendo la probabilidad final en ambos componentes.

Multinomial NB — Frecuencia de términos

Representa el mensaje con **conteos**: captura cuántas veces aparece cada palabra.

$$P(C \mid X) = \frac{\left[\prod_{i=1}^n P(x_i \mid C)^{f_i} \right] \cdot P(C)}{P(X)}$$

$$P(X) = \prod_{i=1}^n P(x_i \mid \text{Spam})^{f_i} \cdot P(\text{Spam}) + \prod_{i=1}^n P(x_i \mid \text{Ham})^{f_i} \cdot P(\text{Ham})$$

donde f_i es la frecuencia del término x_i en el mensaje. A diferencia de Bernoulli, los términos con $f_i = 0$ contribuyen con $P(x_i \mid C)^0 = 1$, por lo que **las palabras ausentes no participan en el cálculo** — ni en el likelihood ni en el evidence.

Caso de uso típico: correos donde la repetición de palabras clave ("gratis", "oferta", "premio") es indicativa de spam.

Multinomial NB — Limitaciones

 Limitación	Explicación
Independencia condicional	Sigue ignorando la coocurrencia entre palabras; "Premio Ganaste" se trata como dos eventos independientes, lo que puede ser simplista en spam más elaborado.
Sensible a la longitud del texto	La relevancia de un término que aparece múltiples veces se diluye en textos largos — su influencia relativa decrece entre el resto de términos presentes.
Concept drift	Su rendimiento no mejora proporcionalmente con más datos si la distribución del spam cambia; no captura eficientemente variaciones drásticas en la redacción de mensajes.

Multinomial NB — Caso práctico

Escenario: 80 HAM / 20 SPAM · Vocabulario: {premio, ganaste, gratis, dinero, oferta} ·

Mensaje: *"Premio Premio Ganaste"* → vector (2, 1, 0, 0, 0)

Posterior:

$$P(\text{Spam} \mid \text{mensaje}) = \frac{[P(\text{premio} \mid \text{Sp})^2 \cdot P(\text{ganaste} \mid \text{Sp})^1] \cdot P(\text{Sp})}{P(X)}$$

Evidence:

$$\begin{aligned} P(X) &= [P(\text{premio} \mid \text{Sp})^2 \cdot P(\text{ganaste} \mid \text{Sp}) \cdot P(\text{Sp})] \\ &+ [P(\text{premio} \mid \text{Ham})^2 \cdot P(\text{ganaste} \mid \text{Ham}) \cdot P(\text{Ham})] \end{aligned}$$

† Nótese que gratis, dinero y oferta ($f_i = 0$) no aparecen en ninguna parte del cálculo — a diferencia de Bernoulli, su ausencia no penaliza ni sesga el resultado. Además, la repetición de "premio" ($f_i = 2$) amplifica su influencia en el posterior.

Bernoulli vs Multinomial — Trade-offs

Dimensión	Bernoulli	Multinomial
Representación	Binaria (presencia/ausencia)	Conteos o TF-IDF
Términos ausentes	Penaliza explícitamente	Los ignora
Longitud del texto	Peor para textos largos	Mejor para textos largos
Desempeño en email	Competitivo (palabras clave únicas)	Generalmente superior (frecuencia importa)

En la literatura (Metsis et al., 2006), **Multinomial con binarización** (*boolean*) suele lograr el mejor balance en corpus de correo electrónico.

3. Metodología y experimento

Conjunto de datos — Enron-Spam

- **Fuente:** corpus público derivado de los correos internos de Enron, ampliamente usado como benchmark en detección de spam.
- **Composición:** mensajes etiquetados como **HAM** (correo legítimo corporativo) y **SPAM** (mensajes no deseados añadidos artificialmente).
- **Características:**
 - Vocabulario **corporativo y técnico** en los mensajes HAM (nombres, dominios, hilos internos).
 - Amplia variedad de spam: ofertas, phishing, boletines no solicitados.
- **Consideración:** el corpus no representa todos los escenarios del mundo real (sesgo hacia inglés corporativo); esto se discute en las conclusiones.

Flujo general

1. Carga de datos y **reserva** de una fracción mínima para **despliegue** ($\approx 0.02\%$).
2. **Preprocesamiento**: limpieza de cabeceras y ruido típico de correo, tokenización, *stopwords*, lematización (NLTK).
3. **Representación**: n-gramas (1, 2) con **TF-IDF** o **aparición binaria** según el modelo.
4. **Modelos**: variantes de **Naive Bayes** y **MLPClassifier**; búsqueda de hiperparámetros.
5. **Evaluación**: métricas de clasificación, comparación, curvas ROC, curvas de aprendizaje, tiempos.

Exploración de datos (EDA)

¿Existe una diferencia clara entre correo HAM y SPAM?

Antes de ajustar clasificadores, revisamos si el texto muestra **patrones distintivos** por clase.

Nubes de palabras (HAM vs SPAM)

SPAM - 1-gramas



HAM - 1-gramas



SPAM - 2-gramas




HAM - 2-gramas



Nubes de palabras — Interpretación

- **Spam:** predominan `www`, `http` y `com` en 1 y 2-gramas — la mayoría de correos spam traen **hipervínculos asociados**, señal discriminativa fuerte. Acompañados de vocabulario de captación: `free`, `offer`, `save`, `money`.
- **HAM (Enron):** vocabulario **corporativo muy específico** — `enron` — y comunicación interna: `schedule`, `meeting`, `attached`.

Longitud del texto (HAM vs SPAM)



Longitud del texto — Interpretación

- **SPAM:** correos generalmente más cortos — caja más compacta y bigote superior menor tanto en caracteres como en palabras. Sin embargo, es la clase con los **outliers más extremos** (~20 000 caracteres), lo que refleja una **alta variabilidad**.
- **HAM:** correos típicamente más largos — caja más ancha y mayor distancia entre P50 y P75, con bigote superior más extenso (~3 500 palabras, ~3 500 caracteres). También presenta abundantes outliers de correos muy extensos.
- **Conclusión:** el enorme solapamiento entre clases y la abundancia de outliers en ambas indica que la **longitud sola no es un discriminador confiable** entre HAM y SPAM.


¿Por qué no basta con heurísticas?

El EDA revela que construir reglas simples para separar HAM y SPAM es prácticamente inviable:

- **Longitud:** las distribuciones se solapan casi por completo — un umbral de caracteres o palabras clasificaría mal una fracción inaceptable de correos.
- **Palabras clave:** términos como `subject`, `would` o `please` aparecen en ambas clases — ninguna palabra por sí sola es discriminadora confiable.

→ Se requiere una técnica que evalúe **combinaciones de señales simultáneamente** y de forma **probabilística o paramétrica** — motivando la comparación **Naive Bayes vs MLP**.

Modelos Naive Bayes considerados




Entrenamiento y evaluación

- **Partición:** `train_test_split` **estratificado** (p. ej. 80 % / 20 %), semilla fija.
- **Métricas:** exactitud, precisión, exhaustividad, F1-score; matrices de confusión y **ROC-AUC** donde aplique.
- **Selección:** comparación sistemática entre pipelines y búsqueda de mejores hiperparámetros.

4. Resultados

Curvas ROC



Curvas ROC — Interpretación

- **MLP** lidera con la mejor curva TP vs FP a tasas de FP bajas (0–0.005), pero comparte **AUC = 0.999** con MultinomialNB y ComplementNB — la diferencia es de décimas de punto porcentual, prácticamente **despreciable**.
- **MultinomialBinaryNB** es el único rezagado con AUC = 0.998 — una diferencia de 0.001, igualmente marginal.
- Con 3 de 4 modelos en AUC = 0.999, el **criterio ROC no es suficiente para elegir entre ellos** — la decisión debe apoyarse en otros factores como coste computacional o curvas de aprendizaje.



Curvas de aprendizaje



Curvas de aprendizaje — Interpretación

- **MultinomialNB** es el modelo más estable: training y CV convergen cerca de 0.998, con la **menor desviación estándar** de los cuatro — predicciones consistentes ante datos nuevos, característica clave en entornos productivos.
- **MLP** muestra una caída progresiva en CV conforme crecen los datos de entrenamiento, con una **banda de incertidumbre amplia** — no es overfitting (la diferencia porcentual es mínima), pero sí una señal de menor estabilidad ante datos desconocidos; factor a considerar al elegir modelo, especialmente contrastando con su $AUC = 0.999$.
- **MultinomialBinaryNB** y **ComplementNB** presentan las mayores brechas entre training y CV, con bandas de CV muy amplias — mayor varianza y menor confiabilidad en producción.

Coste computacional



Coste computacional — Interpretación

- **Fit time:** MLP opera un **orden de magnitud por encima** de los modelos NB — si NB tarda 100 minutos en entrenarse, MLP tardaría ~4.000 minutos (~2.5 días).
- **Score time:** MLP es ~×3 más lento que sus contrapartes NB en inferencia — si NB tarda 1h en predecir, MLP tardaría ~3h. Además, su **banda de incertidumbre es la más amplia** de los cuatro modelos, lo que implica un comportamiento impredecible en entornos productivos.
- **NB:** tiempos de entrenamiento e inferencia notablemente inferiores, con bandas de desviación estándar estrechas — comportamiento **estable y predecible** a escala.
- **Conclusión:** un modelo con rendimiento marginalmente superior en AUC pero con un coste computacional ordenes de magnitud mayor, **no es necesariamente la mejor elección** en producción.